

ACP

Thibaut COHENDOZ, Martin LAFARGUE, Quentin LAMOUR

9 avril 2019

1 Représentation des données

1.1 Introduction des notations

Observations de p variables sur n individus :

$$\text{variable } j : x_j = \begin{pmatrix} x_{1,j} \\ \dots \\ \dots \\ \dots \\ x_{n,j} \end{pmatrix} \quad \text{individu } i : e_i = \begin{pmatrix} x_{i,1} \\ x_{i,2} \\ \dots \\ \dots \\ x_{i,p} \end{pmatrix}$$

Pour les individus, on utilisera plus communément la notation: ${}^t e_i = (x_{i,1} \ x_{i,2} \ \dots \ \dots \ x_{i,p})$

Tableau des données :

$$X = \begin{pmatrix} x_{1,1} & \dots & \dots & \dots & x_{1,p} \\ \vdots & \ddots & & & \vdots \\ \vdots & & x_{i,j} & & \vdots \\ \vdots & & & \ddots & \vdots \\ x_{n,1} & \dots & \dots & \dots & x_{n,p} \end{pmatrix}$$

Exemple :

Pour illustrer la partie théorique de notre cours, on développera ici un exemple sur des joueurs de football. On a sélectionné trois joueurs par poste (défenseur, milieu, attaquant) de Premier League (première division anglaise). On a regroupé le prix d'achat (en millions d'euros), la taille de chaque joueur (en cm) ainsi que le nombre de buts, de passes décisives et d'interceptions par match sur l'ensemble de la saison 2017/2018.

Voici le tableau de données :

	Prix	Buts	Passes décisives	Interceptions / match	Taille
V. Van Dijk	77	0	0	1.8	193
L. Koscielny	9.7	2	0	2.2	186
M. Olsson	3.9	0	1	0.9	170
P.Pogba	90	6	10	0.8	191
Sigurdsson	30	4	3	0.5	186
D.Fletcher	1.5	1	1	1	183
S. Kun Aguero	80	21	6	0.2	173
J. Vardy	19.4	20	1	0.1	178
E. Choupo-Moting	6.2	5	5	0.8	191

Définition 1.1. *Matrice des poids*

On considérera que les données ont été recueillies à la suite d'un tirage aléatoire à probabilités égales, et donc que tous les individus ont la même importance. En notant D la matrice des poids,

$$D = \frac{1}{n} I_n$$

1.2 Introduction aux statistiques

Soient les variables suivantes:

$$X = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \text{ et } Y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

On notera $\bar{x}$ la moyenne arithmétique, $Var(X)$ la variance et σ_X l'écart-type de la variable X :

$$\text{On a : } \bar{x} = \frac{1}{n} \sum_{j=1}^n x_j \text{ et } Var(X) = \frac{1}{n} \sum_{j=1}^n (x_j - \bar{x})^2, \text{ d'où : } \sigma = \sqrt{Var(X)} = \sqrt{\frac{\sum_{j=1}^n (x_j - \bar{x})^2}{n}}$$

La covariance entre deux variables X et Y se calcule suivant la formule : $Cov(X, Y) = \frac{1}{n} \sum_{j=1}^n (x_j - \bar{x})(y_j - \bar{y})$

On peut aussi calculer les coefficients de corrélation entre deux variables : $r(X, Y) = \sum_{j=1}^n \frac{(x_j - \bar{x})(y_j - \bar{y})}{\sigma_X \sigma_Y n}$

On peut remarquer que : $r(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X)Var(Y)}}$

1.3 Des données aux corrélations

Définition 1.2. *Centre de gravité*

Soit g le vecteur des moyennes arithmétiques de chaque variable :

$$g = \begin{pmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{pmatrix}$$

On définit le centre de gravité comme la transposée de g :

$${}^t g = (\bar{x}_1 \quad \bar{x}_2 \quad \dots \quad \bar{x}_p)$$

Retour à l'exemple :

Moyennes et écarts-types des variables :

Variables	Prix	Buts	Passes Décisives	Interceptions/match	Taille
Moyenne	35.3	6.6	3	0.92	183
Ecart-Type	34.38	7.72	3.20	0.65	7.73

Centre de gravité :

$${}^t g = (35.3, 6.6, 3, 0.92, 183)$$

Définition 1.3. *Tableau des données centrées réduites et matrice de variance-covariance*

On notera $Z = (z_{i,j})_{i,j \in \llbracket 1,n \rrbracket \times \llbracket 1,p \rrbracket}$ le tableau des données centrées réduites tel que:

$$z_{i,j} = \frac{x_{i,j} - \bar{x}_j}{\sigma_j}$$

Les variables maintenant centrées, on a donc: ${}^t g = 0_{\mathbb{R}^p}$.

On peut introduire la matrice de variance-covariance. Il s'agit d'une matrice carrée contenant la variance de chaque variable sur la diagonale, et covariances entre toutes les paires possibles de variables en dehors de la diagonale. On la calcule avec cette formule :

$$V = {}^t Z D Z$$

Retour à l'exemple :

Détaillons le calcul d'un coefficient :

$$z_{1,1} = \frac{x_{1,1} - \bar{x}_1}{\sigma_1} = \frac{77 - 35.3}{34.38} \approx 1.21$$

Après avoir calculé tous les coefficients, on obtient le tableau des données centrées réduites :

$$Z = \begin{pmatrix} 1.21 & -0.85 & -0.94 & 1.35 & 1.24 \\ -0.74 & -0.59 & -0.94 & 1.96 & 0.33 \\ -0.91 & -0.85 & -0.63 & -0.03 & -1.74 \\ 1.59 & -0.07 & 2.19 & -0.19 & 0.98 \\ -0.15 & -0.33 & 0 & -0.65 & 0.33 \\ -0.98 & -0.72 & -0.63 & 0.12 & -0.06 \\ 1.30 & 1.87 & 0.94 & -1.11 & -1.35 \\ -0.46 & 1.74 & -0.63 & -1.26 & -0.70 \\ -0.85 & -0.20 & 0.63 & -0.19 & 0.98 \end{pmatrix}$$

Par le produit matriciel tZDZ , on trouve la matrice de variance-covariance de notre exemple :

$$V = \begin{pmatrix} 1 & 0.29 & 0.58 & -0.09 & 0.24 \\ 0.29 & 1 & 0.30 & -0.70 & -0.43 \\ 0.58 & 0.30 & 1 & -0.44 & 0.18 \\ -0.09 & -0.70 & -0.44 & 1 & 0.46 \\ 0.24 & -0.43 & 0.18 & 0.46 & 1 \end{pmatrix}$$

Définition 1.4. *Matrice des corrélations*

En reprenant les notations précédentes, on définit les coefficients de corrélation linéaire $r_{j,k}$

$$r_{j,k} = \frac{\sum_{i=1}^n z_{i,j} z_{i,k}}{n}$$

on remarque qu'on a : $\forall (j,k) \in \mathbb{N}^2$, $r_{j,j} = 1$ et $r_{j,k} = r_{k,j}$

On appelle matrice de corrélations, notée R , la matrice regroupant tous les coefficients de corrélation linéaire entre les p variables prises deux à deux :

$$R = \begin{pmatrix} 1 & r_{1,2} & \cdots & r_{1,p} \\ \vdots & 1 & & \vdots \\ \vdots & & \ddots & \vdots \\ r_{p,1} & \cdots & \cdots & 1 \end{pmatrix}$$

Retour à l'exemple :

$$r_{1,2} = \frac{\sum_{i=1}^9 z_{i,1} z_{i,2}}{9} \approx 0.29$$

On obtient la matrice des corrélations :

$$R = \begin{pmatrix} 1 & 0.29 & 0.58 & -0.09 & 0.24 \\ 0.29 & 1 & 0.30 & -0.70 & -0.43 \\ 0.58 & 0.30 & 1 & -0.44 & 0.18 \\ -0.09 & -0.70 & -0.44 & 1 & 0.46 \\ 0.24 & -0.43 & 0.18 & 0.46 & 1 \end{pmatrix}$$

Proposition 1.1.

Les données de la matrice Z étant centrées réduites, on a :

$$R = V = {}^tZDZ$$

On notera par la suite cette matrice V .

1.4 Espace des individus

1.4.1 Généralités

Définition 1.5. *Espace des individus et rappels*

Dans cette partie, F désignera un espace vectoriel de dimension p , qu'on nommera l'espace des individus.

L'espace des individus étant muni du produit scalaire usuel, la distance entre deux individus e_i et e_j est définie par la forme quadratique :

$$d(e_i, e_j)^2 = {}^t(e_i - e_j)I_p(e_i - e_j)$$

Retour à l'exemple :

Calculons la distance entre les individus 5 et 8.

On rappelle que : ${}^te_5 = \begin{pmatrix} -0.15 & -0.33 & 0 & -0.65 & 0.33 \end{pmatrix}$ et ${}^te_8 = \begin{pmatrix} -0.46 & 1.74 & -0.63 & -1.26 & -0.70 \end{pmatrix}$

On obtient comme distance :

$$d(e_5, e_8)^2 \approx 6.23$$

1.4.2 L'inertie

Définition 1.6. *Inertie*

L'inertie totale est la trace de la matrice :

$$I_g(Z) = tr(V) = \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^p z_{i,j}^2$$

Revenons à notre exemple :

$$I_g(Z) = tr(V) = 5$$

1.5 L'espace des variables

Définition 1.7. *Espace des variables*

Dans cette partie, E désignera un espace vectoriel de dimension n , qu'on nommera l'espace des variables.

On choisira comme métrique des poids la matrice des poids D (Définition 1.1.).

L'espace des variables est muni d'un produit scalaire, la distance entre deux variables x_i et x_j est définie par la forme quadratique :

$$d(x_i, x_j)^2 = {}^t(x_i - x_j)D(x_i - x_j)$$

Retour à l'exemple :

Calculons la distance entre les variables 1 et 5.

On rappelle que : $x_1 = \begin{pmatrix} 1.21 \\ -0.74 \\ -0.91 \\ 1.59 \\ -0.15 \\ -0.98 \\ 1.30 \\ -0.46 \\ -0.85 \end{pmatrix}$ et $x_5 = \begin{pmatrix} 1.24 \\ 0.33 \\ -1.74 \\ 0.98 \\ 0.33 \\ -0.06 \\ -1.35 \\ -0.70 \\ 0.98 \end{pmatrix}$

On obtient comme distance :

$$d(x_1, x_5)^2 \approx 1.52$$

2 Analyse

2.1 Axes principaux

On diagonalise maintenant la matrice V dans une base orthonormée pour trouver les valeurs propres ainsi que les vecteurs propres associés. On range les valeurs propres dans la matrice diagonale, en allant de la plus grande valeur propre à la plus petite. On n'a pas à se préoccuper du signe des valeurs propres, car la matrice V étant symétrique positive, ses valeurs propres sont toutes positives.

Définition 2.1. *Axes principaux*

Soit a_i un vecteur propre de V , on a :

$$Va_i = \lambda_i a_i$$

On appellera a_i axe principal.

On admettra que la norme des axes principaux vaut 1.

Retour à l'exemple :

Après diagonalisation de la matrice V , on obtient cette matrice diagonale :

$$\tilde{V} = \begin{pmatrix} 2.30 & 0 & 0 & 0 & 0 \\ 0 & 1.63 & 0 & 0 & 0 \\ 0 & 0 & 0.54 & 0 & 0 \\ 0 & 0 & 0 & 0.37 & 0 \\ 0 & 0 & 0 & 0 & 0.16 \end{pmatrix}$$

et la matrice de passage :

$$P = \begin{pmatrix} -0.30 & 0.57 & -0.63 & 0.20 & 0.37 \\ -0.57 & -0.15 & -0.32 & -0.59 & -0.46 \\ -0.42 & 0.48 & 0.48 & 0.38 & -0.46 \\ 0.57 & 0.21 & -0.43 & 0.13 & 0.65 \\ 0.28 & 0.61 & 0.28 & -0.68 & 0.12 \end{pmatrix}$$

Théorème 2.1.

Le sous-espace F_k de dimension k est engendré par les k vecteurs propres de V associés aux k plus grandes valeurs propres.

Proposition 2.1.

L'inertie est conservée après un changement de base dans une base orthonormée.

Définition 2.2. Pourcentage d'inertie

Le critère le plus utilisé est le pourcentage d'inertie, qui permet de mesurer la qualité du sous-espace F_k :

$$\%_{F_k} = \frac{\lambda_1 + \lambda_2 + \dots + \lambda_k}{I_g} = \frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^p \lambda_j}$$

Remarque :

Il faut aussi prendre en compte le nombre de variables initiales. Un % de 90% n'a pas le même intérêt sur un tableau de 5 variables et sur un tableau de 100 variables.

Retour à l'exemple :

Valeur propre	%	Cumul	%
2,30	46,01	2,30	46,02
1,63	32,55	3,93	78,57
0,54	10,74	4,47	89,31
0,37	7,41	4,84	96,72
0,16	3,28	5	100

Les deux plus grandes valeurs propres contiennent plus de 78% de l'information, ce que nous jugeons suffisant. On s'intéressera donc à l'espace F_2 .

2.2 Projection des individus sur un sous-espace

On cherche à obtenir une représentation approchée du nuage des n individus dans un espace de dimension faible. On veut projeter sur l'espace qui déforme le moins les distances en projection, c'est-à-dire tel que la moyenne des carrés des distances entre projections soit la plus grande possible. Il faut donc que l'inertie du nuage projeté sur le sous-espace F_k soit maximale.

Définition 2.3. Nuage projeté

Soit p_{F_k} la projection orthogonale sur F_k (espace sur lequel on souhaite projeter).

On note $\tilde{P}$ la matrice de p_{F_k} dans la base canonique.

Le nuage projeté est alors associé à la matrice $Z\tilde{P}$.

Proposition 2.2. Inertie du nuage projeté

$$I_g(Z\tilde{P}) = \text{tr}(V\tilde{P})$$

Retour à l'exemple :

On définit $\tilde{P}$ la matrice de projection sur F_2 :

$$\tilde{P} = \begin{pmatrix} -0.30 & 0.57 & 0 & 0 & 0 \\ -0.57 & -0.15 & 0 & 0 & 0 \\ -0.42 & 0.48 & 0 & 0 & 0 \\ 0.57 & 0.21 & 0 & 0 & 0 \\ 0.28 & 0.61 & 0 & 0 & 0 \end{pmatrix}$$

2.3 Composantes principales

Définition 2.4. Composantes principales

Pour une variable z_j , on peut associer un axe de F (espace des individus) et un vecteur de E (espace des variables). On appelle composantes principales les variables c_i de $\mathbb{R}^n$, avec $i \in \llbracket 1, n \rrbracket$ définies par les axes principaux :

$$c_i = Z a_i$$

L'ensemble des variables c_i engendrées par combinaison linéaire des Z forme un sous-espace vectoriel de E .

Remarque importante :


La composante principale c_i est le vecteur renfermant les coordonnées des projections orthogonales des individus sur l'axe défini par a_i .

Retour à l'exemple :

Par produit matriciel, on obtient les deux composantes principales suivantes :


$$c_1 = \begin{pmatrix} 1.63 \\ 2.17 \\ 0.52 \\ -1.20 \\ -0.04 \\ 1.03 \\ -2.87 \\ -1.51 \\ 0.27 \end{pmatrix} \text{ et } c_2 = \begin{pmatrix} 1.41 \\ -0.18 \\ -1.77 \\ 2.53 \\ 0.03 \\ -0.76 \\ -0.15 \\ -1.53 \\ 0.40 \end{pmatrix}$$

On projette nos individus sur les axes principaux :



Remarque :

On peut aussi projeter les variables sur les composantes principales :



Proposition 2.3. Variance d'une composante principale

Soit $c_i \in \mathbb{R}^n$ une composante principale. La variance de c_i est égale à sa valeur propre associée:

$$\text{Var}(c_i) = \lambda_i$$

Proposition 2.4.

Les composantes principales sont vecteurs propres d'une matrice de $\mathcal{M}_n(\mathbb{R})$:

$$Z^t Z D c_i = \lambda_i c_i$$

Retour à l'exemple :

On peut vérifier que c_1 est un vecteur propre de $Z^t Z D$ associé à la valeur propre λ_1 .
En faisant le produit matriciel $Z^t Z D c_1$, on obtient la matrice $\lambda_1 c_1$, avec $\lambda_1 = 2.30$.

3 Interprétation

3.1 Cercle des corrélations

Définition 3.1. Corrélations variables - composantes principales

Pour relier les nouvelles variables c_i aux variable initiales x_j , on peut calculer les coefficients de corrélation linéaire $r(c_i, x_j)$, obtenus par la formule:

$$r(c_i, x_j) = \sqrt{\lambda_i} a_{i,j}$$

Pour mieux visualiser les corrélations, on peut les synthétiser sur une figure, le "cercle des corrélations", où chaque variable est repérée par un point d'abscisse $r(c_1, x_j)$ et d'ordonnée $r(c_2, x_j)$.

Propriété 3.1. Interprétation du cercle de corrélations

On peut distinguer trois situations à analyser en fonction de l'angle entre les droites (Ox_i) et (Ox_j) , noté Θ :

1. $\Theta < 90^\circ$: La corrélation entre les variables x_i et x_j est positive, plus Θ est petit, plus la corrélation est forte.
2. $\Theta > 90^\circ$: La corrélation entre les variables x_i et x_j est négative, plus Θ est grand, plus la corrélation est forte négativement.
3. $\Theta \approx 90^\circ$: La corrélation entre les variables x_i et x_j est nulle, on dit que les variables x_i et x_j ne sont pas corrélées.

Retour à l'exemple :


$$r(c_1, x_1) = \sqrt{\lambda_1} a_{1,1} = -0.46$$

$$r(c_2, x_1) = \sqrt{\lambda_2} a_{2,1} = 0.73$$

On obtient la liste de points suivante :

Abscisses	Ordonnées
-0,46	0,73
-0,86	-0,20
-0,64	0,61
0,87	0,27
0,42	0,78

On trace ensuite le cercle des corrélations :

**Exercice d'application :**

Nous voulons choisir entre deux fournisseurs. Ceux-ci sont notés selon trois critères : les tarifs, la qualité et la solidité financière. Pour le fournisseur 1 les notes sont, sur dix : 4, 8 et 5. Pour le deuxième : 6, 3 et 6.

Bibliographie :

1. **Probabilités, analyse de données et statistiques**, Gilbert Saporta
2. **Probabilités, statistiques et analyses multicritères**, Mathieu Rouault
3. **Cours d'espaces euclidiens** de Emmanuel Montaut
4. **Cours de réduction d'endomorphismes** de Coralie Eyraud-Dubois
5. https://fr.wikipedia.org/wiki/Analyse_en_composantes_principales